

Лабораторная работа №4

«GCC. ПРОЦЕССЫ»

Знакомство с компилятором GCC

Средствами, традиционно используемыми для создания программ для открытых операционных систем, являются инструменты разработчика GNU. Сделаем маленькую историческую справку. Проект GNU был основан в 1984 году Ричардом Столлманом. Его необходимость была вызвана тем, что в то время сотрудничество между программистами было затруднено, так как владельцы коммерческого программного обеспечения чинили многочисленные препятствия такому сотрудничеству. Целью проекта GNU было создание комплекта программного обеспечения под единой лицензией, которая не допускала бы возможности присваивания кем-то эксклюзивных прав на это ПО. Частью этого комплекта и является набор инструментов для разработчика, которым мы будем пользоваться, и который должен входить во все дистрибутивы Linux.

Одним из этих инструментов является компилятор GCC. Первоначально эта аббревиатура расшифровывалась, как GNU C Compiler. Сейчас она означает – GNU Compiler Collection.

Файлы с исходными кодами программ, которые мы будем создавать, это обычные текстовые файлы, и создавать их можно с помощью любого текстового редактора (например, GEdit KWrite, Kate, а также более традиционные для пользователей Linux – vi и emacs).

Помимо текстовых редакторов, существуют специализированные среды разработки со своими встроенными редакторами. Одним из таких средств является KDevelop. Интересно, что в нём есть встроенный редактор и встроенная консоль, расположенная прямо под редактором. Так что можно прямо в одной программе, не переключаясь между окнами, и редактировать код и давать консольные команды.

Создайте отдельный каталог hello. Это будет каталог нашего первого проекта. В нём создайте текстовый файл hello.c со следующим текстом:

```
#include <stdio.h>
int main(void){
    printf("Hello world!\n");
    return(0);
}
```

Затем в консоли зайдите в каталог проекта. Наберите команду:

```
gcc hello.c
```

Теперь посмотрите внимательно, что произошло. В каталоге появился новый файл a.out. Это и есть исполняемый файл. Запустим его. Наберите в консоли:

```
./a.out
```

Программа должна завестись, то есть должен появиться текст:

```
Hello world!
```

Компилятор gcc по умолчанию присваивает всем созданным исполняемым файлам имя a.out. Если хотите назвать его по-другому, нужно к команде на компиляцию добавить флаг -o и имя, которым вы хотите его назвать. Давайте наберём такую команду:

```
gcc hello.c -o hello
```

Мы видим, что в каталоге появился исполняемый файл с названием hello. Запустим его.

```
./hello
```

Как видите, получился точно такой же исполняемый файл, только с удобным для нас названием.

Флаг `-o` является лишь одним из многочисленных флагов компилятора `gcc`. Некоторые другие флаги мы рассмотрим позднее. Чтобы просмотреть все возможные флаги, можно воспользоваться справочной системой `man`. Наберите в командной строке:

```
man gcc
```

Перед вами предстанет справочная система по этой программе. Просмотрите, что означает каждый флаг. С некоторыми из них мы скоро встретимся. Выход из справочной системы осуществляется с помощью клавиши `q`.

Вы, конечно, обратили внимание, что, когда мы запускаем программу из нашего каталога разработки, мы перед названием файла набираем точку и слэш. Зачем же мы это делаем?

Дело в том, что, если мы наберём только название исполняемого файла, операционная система будет искать его в каталогах `/usr/bin` и `/usr/local/bin`, и, естественно, не найдёт. Каталоги `/usr/bin` и `/usr/local/bin` – системные каталоги размещения исполняемых программ. Первый из них предназначен для размещения стабильных версий программ, как правило, входящих в дистрибутив Linux. Второй – для программ, устанавливаемых самим пользователем (за стабильность которых никто не ручается). Такая система нужна, чтобы отделить их друг от друга. По умолчанию при сборке программы устанавливаются в каталог `/usr/local/bin`. Крайне нежелательно помещать что-либо лишнее в `/usr/bin` или удалять что-то оттуда вручную, потому что это может привести к краху системы. Там должны размещаться программы, за стабильность которых отвечают разработчики дистрибутива.

Чтобы запустить программу, находящуюся в другом месте, надо прописать полный путь к ней, например так:

```
/home/myuser/projects/hello/hello
```

Или другой вариант: прописать путь относительно текущего каталога, в котором вы в данный момент находитесь в консоли. При этом одна точка означает текущий каталог, две точки – родительский. Например, команда `./hello` запускает программу `hello`, находящуюся в текущем каталоге, команда `../hello` – программу `hello`, находящуюся в родительском каталоге, команда `./projects/hello/hello` – программу во вложенных каталогах, находящихся внутри текущего.

Есть возможность добавлять в список системных путей к программам дополнительные каталоги. Для этого надо добавить новый путь в системную переменную `PATH`. Но давайте пока не будем отвлекаться от главной темы. Переменные окружения – это отдельный разговор.

Теперь рассмотрим, что же делает программа `gcc`. Её работа включает три этапа: обработка препроцессором, компиляция и компоновка (или линковка).

Препроцессор включает в основной файл содержимое всех заголовочных файлов, указанных в директивах `#include`. В заголовочных файлах обычно находятся объявления функций, используемых в программе, но не определённых в тексте программы. Их определения находятся где-то в другом месте: или в других файлах с исходным кодом или в бинарных библиотеках (*ключ – E*).

Вторая стадия – компиляция. Она заключается в превращении текста программы на языке C/C++ в набор машинных команд. Результат сохраняется в объектном файле. Разумеется, на машинах с разной архитектурой процессора двоичные файлы получаются в разных форматах, и на одной машине невозможно запустить бинарный файл собранный на другой машине (разве только, если у них одинаковая архитектура процессора и одинаковые операционные системы). Вот почему программы для UNIX– подобных систем распространяются в виде исходных кодов: они должны быть доступны всем пользователям, независимо от того, у кого какой процессор и какая операционная система (*ключ – c*).

Последняя стадия – компоновка. Она заключается в связывании всех объектных файлов проекта в один, связывании вызовов функций с их определениями, и присоединением библиотечных файлов, содержащих функции, которые вызываются, но не определены в проекте. В результате формируется запускаемый файл – наша конечная цель. Если какая-то функция в программе используется, но компоновщик не найдёт место, где эта функция определена, он выдаст сообщение об ошибке, и откажется создавать исполняемый файл (*ключ – o*).

Если мы создаём объектный файл из исходного файла, уже обработанного препроцессором (например, такого, какой мы получили выше), то мы должны обязательно указать явно, что компилируемый файл является файлом исходного кода, обработанный препроцессором, и имеющий теги препроцессора. В противном случае он будет обрабатываться, как обычный файл C++, без учёта тегов препроцессора, а, значит, связь с объявленными функциями не будет устанавливаться. Для явного указания на язык и формат обрабатываемого файла служит опция `-x`. Файл C++, обработанный препроцессором обозначается `cxx-output`.

```
gcc -x cxx-output -c prog.c
```

Наконец, последний этап – компоновка. Получаем из объектного файла исполняемый.

```
gcc prog.o -o prog
```

Можно его запускать.

```
./prog
```

Вы спросите: «Зачем вся эта возня с промежуточными этапами? Не лучше ли просто один раз скомандовать `gcc prog.c -o prog`?»

Дело в том, что настоящие программы очень редко состоят из одного файла. Как правило, исходных файлов несколько, и они объединены в проект. И в некоторых исключительных случаях программу приходится компоновать из нескольких частей, написанных на разных языках. В этом случае приходится запускать компиляторы разных языков, чтобы каждый получил объектный файл из своего исходника, а затем уже эти полученные объектные файлы компоновать в исполняемую программу.

Пример проекта из нескольких файлов

Напишем теперь программу, состоящую из двух исходных файлов и одного заголовочного. Для этого возьмём наш калькулятор и переделаем его. Теперь после введения первого числа надо сразу вводить действие. Если действие оперирует только с одним числом (как в случае синуса, косинуса, тангенса, квадратного корня), результат сразу будет выведен. Если понадобится второе число, оно будет специально запрашиваться.

Создадим каталог проекта `kalkul2`. В нём создадим три файла: `calculate.h`, `calculate.c`, `main.c`.

Файл `calculate.h`:

```
////////////////////////////////////
// calculate.h
#ifndef CALCULATE_H_
#define CALCULATE_H_
float Calculate(float Numeral, char Operation[4]);
#endif /*CALCULATE_H_*/
```

Файл `calculate.c`:

```
////////////////////////////////////
// calculate.c
#include <stdio.h>
#include <math.h>
#include <string.h>
```

```

#include "calculate.h"
float Calculate(float Numeral, char Operation[4])
{
    float SecondNumeral;
    if(strncmp(Operation, "+", 1) == 0)
    {
        printf("Второе слагаемое: ");
        scanf("%f", &SecondNumeral);
        return(Numeral + SecondNumeral);
    }
    else if(strncmp(Operation, "-", 1) == 0)
    {
        printf("Вычитаемое: ");
        scanf("%f", &SecondNumeral);
        return(Numeral - SecondNumeral);
    }
    else if(strncmp(Operation, "*", 1) == 0)
    {
        printf("Множитель: ");
        scanf("%f", &SecondNumeral);
        return(Numeral * SecondNumeral);
    }
    else if(strncmp(Operation, "/", 1) == 0)
    {
        printf("Делитель: ");
        scanf("%f", &SecondNumeral);
        if(SecondNumeral == 0)
        {
            printf("Ошибка: деление на ноль! ");
            return(HUGE_VAL);
        }
        else
            return(Numeral / SecondNumeral);
    }
    else if(strncmp(Operation, "pow", 3) == 0)
    {
        printf("Степень: ");
        scanf("%f", &SecondNumeral);
        return(pow(Numeral, SecondNumeral));
    }
    else if(strncmp(Operation, "sqrt", 4) == 0)
        return(sqrt(Numeral));
    else if(strncmp(Operation, "sin", 3) == 0)
        return(sin(Numeral));
    else if(strncmp(Operation, "cos", 3) == 0)
        return(cos(Numeral));
    else if(strncmp(Operation, "tan", 3) == 0)
        return(tan(Numeral));
    else
    {
        printf("Неправильно введено действие ");
        return(HUGE_VAL);
    }
}

```

Файл **main.c**:

```

////////////////////////////////////
// main.c
#include <stdio.h>
#include "calculate.h"
int main(void)
{
    float Numeral;
    char Operation[4];

```

```

float Result;
printf("Число: ");
scanf("%f", &Numeral);
printf("Арифметическое действие (+, - , *, /, pow, sqrt, sin, cos, tan): ");
scanf("%s", &Operation);
Result = Calculate(Numeral, Operation);
printf("%.2f\n", Result);
return 0;
}

```

У нас есть два файла исходного кода (с- файлы) и один заголовочный (h- файл). Заголовочный включается в оба с- файла.

Скомпилируем calculate.c.

```
gcc -c calculate.c -o calculate.o
```

Получили calculate.o. Затем main.c.

```
gcc -c main.c -o main.o
```

И вот он main.o перед нами! Теперь, как вам уже, наверное, подсказывает интуиция, надо из этих двух объектных файлов сделать запускаемый.

```
gcc calculate.o main.o -o kalkul
```

Упс... и не получилось... Вместо столь желаемого запускаемого файла, в консоли появилась какая-то ругань:

```

calculate.o(.text+0x1b5): In function 'Calculate':
calculate.c: undefined reference to 'pow'
calculate.o(.text+0x21e):calculate.c: undefined reference to 'sqrt'
calculate.o(.text+0x274):calculate.c: undefined reference to 'sin'
calculate.o(.text+0x2c4):calculate.c: undefined reference to 'cos'
calculate.o(.text+0x311):calculate.c: undefined reference to 'tan'
collect2: ld returned 1 exit status

```

Давайте разберёмся, за что нас так отругали. Undefined reference означает ссылку на функцию, которая не определена. В данном случае gcc не нашёл определения функций pow, sqrt, sin, cos, tan. Где же их найти?

Как уже говорилось раньше, определения функций могут находиться в библиотеках. Это скомпилированные двоичные файлы, содержащие коллекции однотипных операций, которые часто вызываются из многих программ, а потому нет смысла многократно писать их код в программах. Стандартное расположение файлов библиотек-каталоги /usr/lib и /usr/local/lib (при желании можно добавить путь). Если библиотечный файл имеет расширение "*.a", то это статическая библиотека, то есть при компоновке весь её двоичный код включается в исполняемый файл. Если расширение .so, то это динамическая библиотека. Это значит в исполняемый файл программы помещается только ссылка на библиотечный файл, а уже из него и запускается функция.

Когда мы писали программу hello, мы использовали функцию printf для вывода текстовой строки. Однако, как вы помните, мы нигде не писали определения этой функции. Откуда же она тогда вызывается?

Просто при компоновке любой программы компилятор gcc по умолчанию включает в запускаемый файл библиотеку libc. Это стандартная библиотека языка C. Она содержит рутинные функции, необходимые абсолютно во всех программах, написанных на C, в том числе и функцию printf. Поскольку библиотека libc нужна во всех программах, она включается по умолчанию, без необходимости давать отдельное указание на её включение.

Остальные библиотеки надо требовать включать явно. Ведь нельзя же во все программы помещать абсолютно все библиотеки. Тогда исполняемый файл раздуется до немыслимо крупных размеров. Одним программам нужны одни функции, другим – другие. Зачем же засорять их ненужным кодом! Пусть остаётся только то, что реально необходимо.

Нам в данном случае нужна библиотека `libm`. Именно она содержит все основные математические функции. Она требует включения в текст программы заголовочного файла `<math.h>`.

Помимо этого дистрибутивы Linux содержат другие библиотеки, например:

- `libGL` Вывод трёхмерной графики в стандарте OpenGL. Требуется заголовочный файл `<GL/gl.h>`.
- `libcrypt` Криптографические функции. Требуется заголовочный файл `<crypt.h>`.
- `libcurses` Псевдографика в символьном режиме. Требуется заголовочный файл `<curses.h>`.
- `libform` Создание экранных форм в текстовом режиме. Требуется заголовочный файл `<form.h>`.
- `libgthread` Поддержка многопоточного режима. Требуется заголовочный файл `<glib.h>`.
- `libgtk` Графическая библиотека в режиме X Window. Требуется заголовочный файл `<gtk/gtk.h>`.
- `libhistory` Работы с журналами. Требуется заголовочный файл `<readline/readline.h>`.
- `libjpeg` Работа с изображениям в формате JPEG. Требуется заголовочный файл `<jpeglib.h>`.
- `libncurses` Работа с псевдографикой в символьном режиме. Требуется заголовочный файл `<ncurses.h>`.

• `libpng` Работа с графикой в формате PNG. Требуется заголовочный файл `<png.h>`.

• `libpthread` Многопоточная библиотека POSIX. Стандартная многопоточная библиотека для Linux. Требуется заголовочный файл `<pthread.h>`.

• `libreadline` Работа с командной строкой. Требуется заголовочный файл `<readline/readline.h>`.

• `libtiff` Работа с графикой в формате TIFF. Требуется заголовочный файл `<tiffio.h>`.

• `libvga` Низкоуровневая работа с VGA и SVGA. Требуется заголовочный файл `<vga.h>`.

А также многие-многие другие.

Обратите внимание, что названия всех этих библиотек начинаются с буквосочетания `lib`. Для их явного включения в исполняемый файл, нужно добавить к команде `gcc` опцию `-l`, к которой слитно прибавить название библиотеки без `lib`. Например, чтобы включить библиотеку `libvga` надо указать опцию `-lvga`.

Нам нужны математические функции `pow`, `sqrt`, `sin`, `cos`, `tan`. Они, как уже было сказано, находятся в математической библиотеке `libm`. Следовательно, чтобы подключить эту библиотеку, мы должны указать опцию `-lm`.

```
gcc calculate.o main.o -o kalkul -lm
```

Ура! Наконец-то наш запускаемый файл создан!

Make-файлы

У вас, вероятно, появился вопрос: можно ли не компилировать эти файлы по отдельности, а собрать сразу всю программу одной командой? Можно.

```
gcc calculate.c main.c -o kalkul -lm
```

Вы скажете, что это удобно? Удобно для нашей программы, потому что она состоит всего из двух с-файлов. Однако профессиональная программа может состоять из нескольких десятков таких файлов. Каждый раз набирать названия их всех в одной строке было бы делом чрезмерно утомительным. Но есть возможность решить эту проблему. Названия всех исходных файлов и все команды для сборки программы можно поместить в отдельный текстовый файл. А потом считывать их оттуда одной короткой командой.

Давайте создадим такой текстовый файл и воспользуемся им. В каталоге проекта `kalkul2` удалите все файлы, кроме `calculate.h`, `calculate.c`, `main.c`. Затем создайте в этом же каталоге новый файл, назовите его `Makefile` (без расширений). Поместите туда следующий текст.

```
kalkul: calculate.o main.o
    gcc calculate.o main.o -o kalkul -lm
calculate.o: calculate.c calculate.h
    gcc -c calculate.c
main.o: main.c calculate.h
    gcc -c main.c
```

```
clean:
    rm - f kalkul calculate.o main.o
install:
    cp kalkul /usr/local/bin/kalkul
uninstall:
    rm - f /usr/local/bin/kalkul
```

Обратите внимание на строки, введенные с отступом от левого края. Этот отступ получен с помощью клавиши **Tab**. Только так его и надо делать! Если будете использовать клавишу «Пробел», команды не будут исполняться.

Затем дадим команду, состоящую всего из одного слова:

```
make
```

И сразу же в нашем проекте появляются и объектные файлы и запускаемый файл. Программа `make` как раз и предназначена для интерпретации команд, находящихся в файле со стандартным названием `Makefile`. Рассмотрим его структуру.

`Makefile` является списком правил. Каждое правило начинается с указателя, называемого «Цель». После него стоит двоеточие, а далее через пробел указываются зависимости. В нашем случае ясно, что конечный файл `kalkul` зависит от объектных файлов `calculate.o` и `main.o`. Поэтому они должны быть собраны прежде сборки `kalkul`. После зависимостей пишутся команды. Каждая команда должна находиться на отдельной строке, и отделяться от начала строки клавишей `Tab`. Структура правила `Makefile` может быть очень сложной. Там могут присутствовать переменные, конструкции ветвления, цикла. Этот вопрос требует отдельного подробного изучения.

Если мы посмотрим на три первых правила, то они нам хорошо понятны. Там те же самые команды, которыми мы уже пользовались. А что же означают правила `clean`, `install` и `uninstall`?

В правиле `clean` стоит команда `rm`, удаляющая исполняемый и объектные файлы. Флаг `- f` означает, что, если удаляемый файл отсутствует, программа должна это проигнорировать, не выдавая никаких сообщений. Итак, правило `clean` предназначено для «очистки» проекта, приведения его к такому состоянию, в каком он был до команды `make`.

Запустите:

```
make
```

Появились объектные файлы и исполняемый. Теперь:

```
make clean
```

Объектные и исполняемый файлы исчезли. Остались только `s`-файлы, `h`-файл и сам `Makefile`. То есть, проект «очистился» от результатов команды `make`.

Правило `install` помещает исполняемый файл в каталог `/usr/local/bin` – стандартный каталог размещения пользовательских программ. Это значит, что её можно будет вызывать из любого места простым набором её имени. Но помещать что-либо в этот каталог можно только, зайдя в систему под «суперпользователем». Для этого надо дать команду `su` и набрать пароль «суперпользователя». В противном случае система укажет, что вам отказано в доступе. Выход из «суперпользователя» осуществляется командой `exit`. Итак,

```
make
su
make install
exit
```

Теперь вы можете запустить эту программу просто, введя имя программы, без прописывания пути.

```
kalkul
```

Можете открыть каталог `/usr/local/bin`. Там должен появиться файл с названием `kalkul`. Давайте теперь «уберём за собой», не будем засорять систему.

```
su
make uninstall
exit
```

Посмотрите каталог `/usr/local/bin`. Файл `kalkul` исчез. Итак, правило `uninstall` удаляет программу из системного каталога.

Процессы

Контекст процесса

Контекст процесса складывается из пользовательского контекста и контекста ядра, как изображено на рисунке.

Под пользовательским контекстом процесса понимают код и данные, расположенные в адресном пространстве процесса. Все данные подразделяются на:

- инициализируемые неизменяемые данные (например, константы);
- инициализируемые изменяемые данные (все переменные, начальные значения которых присваиваются на этапе компиляции);
- неинициализируемые изменяемые данные (все статические переменные, которым не присвоены начальные значения на этапе компиляции);
- стек пользователя;
- данные, расположенные в динамически выделяемой памяти (например, с помощью стандартных библиотечных C функций `malloc()`, `calloc()`, `realloc()`).

Исполняемый код и инициализируемые данные составляют содержимое файла программы, который выполняется в контексте процесса. Пользовательский стек применяется при работе процесса в пользовательском режиме (`user-mode`).

Под понятием "контекст ядра" объединяются системный контекст и регистровый контекст, рассмотренные на лекции. Мы будем выделять в контексте ядра стек ядра, который используется при работе процесса в режиме ядра (`kernel mode`), и данные ядра, хранящиеся в структурах, являющихся аналогом блока управления процессом — PCB. Состав данных ядра будет уточняться на последующих семинарах. На этом занятии нам достаточно знать, что в данные ядра входят: идентификатор пользователя — `UID`, групповой идентификатор пользователя — `GID`, идентификатор процесса — `PID`, идентификатор родительского процесса — `PPID`.

Идентификация процесса

Каждый процесс в операционной системе получает уникальный идентификационный номер — `PID` (`process identifier`). При создании нового процесса операционная система пытается присвоить ему свободный номер больший, чем у процесса, созданного перед ним. Если таких свободных номеров не оказывается (например, мы достигли максимально возможного номера для процесса), то операционная система выбирает минимальный номер из всех свободных номеров. В операционной системе Linux присвоение идентификационных номеров процессов начинается с номера 0, который получает процесс `kernel` при старте операционной системы. Этот номер впоследствии не может быть присвоен никакому другому процессу. Максимально возможное значение для номера процесса в Linux на базе 32-разрядных процессоров Intel составляет $2^{31}-1$.

Иерархия процессов

В операционной системе UNIX все процессы, кроме одного, создающегося при старте операционной системы, могут быть порождены только какими — либо другими процессами. В качестве прародителя всех остальных процессов в подобных UNIX системах могут

выступать процессы с номерами 1 или 0. В операционной системе Linux таким родоначальником, существующим только при загрузке системы, является процесс kernel с идентификатором 0.

Таким образом, все процессы в UNIX связаны отношениями процесс-родитель – процесс-ребенок и образуют генеалогическое дерево процессов. Для сохранения целостности генеалогического дерева в ситуациях, когда процесс-родитель завершает свою работу до завершения выполнения процесса-ребенка, идентификатор родительского процесса в данных ядра процесса-ребенка (PPID – parent process identifier) изменяет свое значение на значение 1, соответствующее идентификатору процесса init, время жизни которого определяет время функционирования операционной системы. Тем самым процесс init как бы усыновляет осиротевшие процессы. Наверное, логичнее было бы заменять PPID не на значение 1, а на значение идентификатора ближайшего существующего процесса-прародителя умершего процесса-родителя, но в UNIX почему-то такая схема реализована не была.

Системные вызовы getppid() и getpid()

Данные ядра, находящиеся в контексте ядра процесса, не могут быть прочитаны процессом непосредственно. Для получения информации о них процесс должен совершить соответствующий системный вызов. Значение идентификатора текущего процесса может быть получено с помощью системного вызова getpid(), а значение идентификатора родительского процесса для текущего процесса – с помощью системного вызова getppid(). Прототипы этих системных вызовов и соответствующие типы данных описаны в системных файлах <sys/types.h> и <unistd.h>. Системные вызовы не имеют параметров и возвращают идентификатор текущего процесса и идентификатор родительского процесса соответственно.

Системные вызовы getpid() и getppid() Прототипы системных вызовов

```
#include <sys/types.h>
#include <unistd.h>
pid_t getpid(void);
```

Описание системных вызовов

Системный вызов getpid возвращает идентификатор текущего процесса. Системный вызов getppid возвращает идентификатор процесса-родителя для текущего процесса. Тип данных pid_t является синонимом для одного из целочисленных типов языка C.

Создание процесса в UNIX. Системный вызов fork()

В операционной системе UNIX новый процесс может быть порожден единственным способом – с помощью системного вызова fork(). При этом вновь созданный процесс будет являться практически полной копией родительского процесса. У порожденного процесса по сравнению с родительским процессом (на уровне уже полученных знаний) изменяются значения следующих параметров: идентификатор процесса – PID; идентификатор родительского процесса – PPID.

Системный вызов для порождения нового процесса

Прототип системного вызова

```
#include <sys/types.h>
#include <unistd.h>
pid_t fork(void);
```

Описание системного вызова

Системный вызов `fork` служит для создания нового процесса в операционной системе UNIX. Процесс, который инициировал системный вызов `fork`, принято называть родительским процессом (parent process). Вновь порожденный процесс принято называть процессом-ребенком (child process). Процесс-ребенок является почти полной копией родительского процесса. У порожденного процесса по сравнению с родительским изменяются значения следующих параметров:

- идентификатор процесса;
- идентификатор родительского процесса;
- время, оставшееся до получения сигнала SIGALRM;
- сигналы, ожидавшие доставки родительскому процессу, не будут доставляться порожденному процессу.

При однократном системном вызове возврат из него может произойти дважды: один раз в родительском процессе, а второй раз в порожденном процессе. Если создание нового процесса произошло успешно, то в порожденном процессе системный вызов вернет значение 0, а в родительском процессе – положительное значение, равное идентификатору процесса-ребенка. Если создать новый процесс не удалось, то системный вызов вернет в инициировавший его процесс отрицательное значение.

Системный вызов `fork` является единственным способом породить новый процесс после инициализации операционной системы UNIX.

В процессе выполнения системного вызова `fork()` порождается копия родительского процесса и возвращение из системного вызова будет происходить уже как в родительском, так и в порожденном процессах. Этот системный вызов является единственным, который вызывается один раз, а при успешной работе возвращается два раза (один раз в процессе-родителе и один раз в процессе-ребенке)! После выхода из системного вызова оба процесса продолжают выполнение регулярного пользовательского кода, следующего за системным вызовом.

Для того чтобы после возвращения из системного вызова `fork()` процессы могли определить, кто из них является ребенком, а кто родителем, и, соответственно, по-разному организовать свое поведение, системный вызов возвращает в них разные значения. При успешном создании нового процесса в процесс-родитель возвращается положительное значение, равное идентификатору процесса-ребенка. В процесс-ребенок же возвращается значение 0. Если по какой-либо причине создать новый процесс не удалось, то системный вызов вернет в инициировавший его процесс значение -1. Таким образом, общая схема организации различной работы процесса-ребенка и процесса-родителя выглядит так:

```
pid = fork();
if(pid == -1){
    ...
    /* ошибка */
    ...
} else if (pid == 0){
    ...
    /* ребенок */
    ...
} else {
    ...
    /* родитель */
    ...
}
```

Завершение процесса. Функция exit()

Существует два способа корректного завершения процесса в программах, написанных на языке C. Первый способ мы использовали до сих пор: процесс корректно завершался по достижении конца функции main() или при выполнении оператора return в функции main(), второй способ применяется при необходимости завершить процесс в каком-либо другом месте программы. Для этого используется функция exit() из стандартной библиотеки функций для языка C. При выполнении этой функции происходит сброс всех частично заполненных буферов ввода-вывода с закрытием соответствующих потоков, после чего инициируется системный вызов прекращения работы процесса и перевода его в состояние **закончил исполнение**. Возврата из функции в текущий процесс не происходит и функция ничего не возвращает. Значение параметра функции exit() – кода завершения процесса – передается ядру операционной системы и может быть затем получено процессом, породившим завершившийся процесс. На самом деле при достижении конца функции main() также неявно вызывается эта функция со значением параметра 0.

Функция для нормального завершения процесса

Прототип функции

```
#include <stdlib.h>
void exit(int status);
```

Описание функции

Функция exit служит для нормального завершения процесса. При выполнении этой функции происходит сброс всех частично заполненных буферов ввода-вывода с закрытием соответствующих потоков (файлов, pipe, FIFO, сокетов), после чего инициируется системный вызов прекращения работы процесса и перевода его в состояние закончил исполнение. Возврата из функции в текущий процесс не происходит, и функция ничего не возвращает.

Значение параметра status (кода завершения процесса) передается ядру операционной системы и может быть затем получено процессом, породившим завершившийся процесс. При этом используются только младшие 8 бит параметра, так что для кода завершения допустимы значения от 0 до 255. По соглашению, код завершения 0 означает безошибочное завершение процесса.

Если процесс завершает свою работу раньше, чем его родитель, и родитель явно не указал, что он не хочет получать информацию о статусе завершения порожденного процесса, то завершившийся процесс не исчезает из системы окончательно, а остается в состоянии закончил исполнение либо до завершения процесса-родителя, либо до того момента, когда родитель получит эту информацию. Процессы, находящиеся в состоянии закончил исполнение, в операционной системе UNIX принято называть процессами-зомби (zombie, defunct).

Изменение пользовательского контекста процесса. Семейство функций для системного вызова exec().

Для изменения пользовательского контекста процесса применяется системный вызов exec(), который пользователь не может вызвать непосредственно. Вызов exec() заменяет пользовательский контекст текущего процесса на содержимое некоторого исполняемого файла и устанавливает начальные значения регистров процессора (в том числе устанавливает программный счетчик на начало загружаемой программы). Этот вызов требует для своей работы задания имени исполняемого файла, аргументов командной строки и параметров окружающей среды. Для осуществления вызова программист может воспользоваться одной из шести функций: execlp(), execvp(), execl() и, execv(), execl(), execve(), отличающихся друг от друга представлением параметров, необходимых для работы системного вызова exec().

Функции изменения пользовательского контекста процесса

Прототипы функций

```
#include <unistd.h>
int execlp(const char *file,
const char *arg0,
... const char *argN,(char *)NULL)
int execvp(const char *file, char *argv[])
int execl(const char *path,
const char *arg0,
... const char *argN,(char *)NULL)
int execv(const char *path, char *argv[])
int execlp(const char *path,
const char *arg0,
... const char *argN,(char *)NULL,
char * envp[])
int execve(const char *path, char *argv[],
char *envp[])
```

Описание функций

Для загрузки новой программы в системный контекст текущего процесса используется семейство взаимосвязанных функций, отличающихся друг от друга формой представления параметров.

Аргумент `file` является указателем на имя файла, который должен быть загружен. Аргумент `path` –это указатель на полный путь к файлу, который должен быть загружен.

Аргументы `arg0`, ..., `argN` представляют собой указатели на аргументы командной строки. Заметим, что аргумент `arg0` должен указывать на имя загружаемого файла. Аргумент `argv` представляет собой массив из указателей на аргументы командной строки. Начальный элемент массива должен указывать на имя загружаемой программы, а заканчиваться массив должен элементом, содержащим указатель `NULL`.

Аргумент `envp` является массивом указателей на параметры окружающей среды, заданные в виде строк "переменная=строка". Последний элемент этого массива должен содержать указатель `NULL`.

Поскольку вызов функции не изменяет системный контекст текущего процесса, загруженная программа унаследует от загрузившего ее процесса следующие атрибуты:

- идентификатор процесса;
- идентификатор родительского процесса;
- групповой идентификатор процесса;
- идентификатор сеанса;
- время, оставшееся до возникновения сигнала `SIGALRM`;
- текущую рабочую директорию;
- маску создания файлов;
- идентификатор пользователя;
- групповой идентификатор пользователя;
- явное игнорирование сигналов;
- таблицу открытых файлов (если для файлового дескриптора не устанавливался признак "закрыть файл при выполнении `exec()`").

В случае успешного выполнения возврата из функций в программу, осуществившую вызов, не происходит, а управление передается загруженной программе. В случае неудачного выполнения в программу, инициировавшую вызов, возвращается отрицательное значение.

Поскольку системный контекст процесса при вызове `exec()` остается практически неизменным, большинство атрибутов процесса, доступных пользователю через системные вызовы (PID, UID, GID, PPID и другие, смысл которых станет понятен по мере углубления наших знаний на дальнейших занятиях), после запуска новой программы также не изменяется.

Важно понимать разницу между системными вызовами `fork()` и `exec()`. Системный вызов `fork()` создает новый процесс, у которого пользовательский контекст совпадает с пользовательским контекстом процесса-родителя. Системный вызов `exec()` изменяет пользовательский контекст текущего процесса, не создавая новый процесс.

Пример

№	fork	exec	
0	0112	4	ls

```
#include <unistd.h>
#include <sys/types.h>
#include <stdio.h>
#include <stdlib.h>
int main(){
    pid_t pid;
    printf("Порождение процесса 1 PID = %d PPID = %d\n", getpid(),
getppid());

    // Порождение второго процесса
    if ((pid = fork()) == -1)
        printf("Ошибка!\n");
    else if (pid == 0) {
        printf("Порождение процесса 2 PID = %d PPID = %d\n", getpid(),
getppid());
        // Порождение четвертого процесса
        if ((pid = fork()) == -1)
            printf("Ошибка!\n");
        else if (pid == 0){
            printf("Порождение процесса 4 PID = %d PPID = %d\n",
getpid(), getppid());
            printf("Завершился процесс 4 PID = %d PPID = %d\n",
getpid(), getppid());
            execl("/bin/ls", "ls", NULL);
        }
        printf("Завершился процесс 2 PID = %d PPID = %d\n", getpid(),
getppid());
        exit(0);
    } else sleep(1); //задержка родительского процесса

    // Порождение третьего процесса
    if ((pid = fork()) == -1)
        printf("Ошибка!\n");
    else if (pid == 0) {
        printf("Порождение 3 PID = %d PPID = %d\n", getpid(), getppid());
        printf("Завершился процесс 3: PID = %d, PPID = %d\n", getpid(),
getppid());
        exit(0);
    } else sleep(1);
    printf("Завершился процесс 1: PID = %d, PPID = %d\n", getpid(),
getppid());
```

```

    exit(0);
    return 1;
}

```

Задание для выполнения

Написать программу, которая будет реализовывать следующие функции:

- сразу после запуска получает и сообщает свой ID и ID родительского процесса;
- перед каждым выводом сообщения об ID процесса и родительского процесса эта информация получается заново;
- порождает процессы, формируя генеалогическое дерево согласно варианту, сообщая, что "процесс с ID таким-то породил процесс с таким-то ID";
- перед завершением процесса сообщить, что "процесс с таким-то ID и таким-то ID родителя завершает работу";
- один из процессов должен вместо себя запустить программу, указанную в варианте задания.

На основании выходной информации программы предыдущего пункта изобразить генеалогическое дерево процессов (с указанием идентификаторов процессов). Объяснить каждое выведенное сообщение и их порядок в предыдущем пункте.

Варианты индивидуальных заданий

В столбце **fork** описано генеалогическое дерево процессов: каждая цифра указывает на относительный номер (не путать с pid) процесса, являющегося родителем для данного процесса. Например, строка

0 1 1 1 3

означает, что первый процесс не имеет родителя среди ваших процессов (порождается и запускается извне), второй, третий и четвертый – порождены первым, пятый – третьим.

В столбце **exec** указан номер процесса, выполняющего вызов **exec**, команды для которого указаны в последнем столбце. Запускайте команду обязательно с какими-либо параметрами.

№	fork	exec	
1	0 1 1 1 3 3 5	1	ls -l
2	0 1 2 2 3 4 6	2	ps -a
3	0 1 1 2 2 5 6	3	pwd
4	0 1 1 1 2 5 3	4	whoami
5	0 1 1 2 2 3 3	5	df
6	0 1 1 2 4 4 4	6	ls
7	0 1 1 1 3 3 2	7	ps -u [user]
8	0 1 2 2 3 4 5	1	pwd
9	0 1 1 2 2 5 6	2	whoami
10	0 1 1 1 2 5 5	3	who -a
11	0 1 1 2 2 3 4	4	ls [directory]
12	0 1 1 2 4 4 5	5	ps [process]
13	0 1 1 1 3 3 5	6	pwd
14	0 1 2 2 3 4 6	7	who
15	0 1 1 2 2 5 5	1	date
16	0 1 1 1 2 5 4	2	ls -a [directory]
17	0 1 1 2 2 3 3	3	ps
18	0 1 1 2 4 4 6	4	pwd
19	0 1 1 2 2 5 5	5	whoami
20	0 1 1 1 2 5 4	6	free

Отчет

Как и в других работах, отчет по проделанной работе представляется преподавателю в стандартной форме: на листах формата А4, с титульным листом (включающим тему, фео, номер зачетки и пр.), целью, ходом работы и выводами по выполненной работе. Каждое задание должно быть отражено в отчете следующим образом: 1) что надо было сделать, 2) как это сделали, 3) что получилось, и, в зависимости от задания – 4) почему получилось именно так, а не иначе. При наличии заданий с вариантами необходимо указать свой вариант, и расчет его номера, а также всё вышеуказанное для данного варианта задания.

